

**FATEC SOROCABA – CENTRO PAULA SOUZA
CURSO DE ANÁLISE E DESENVOLVIMENTO DE SISTEMAS**

**DO DADO BRUTO À DECISÃO: CONSTRUÇÃO DE UM DATA
WAREHOUSE PARA MONITORAMENTO DA QUALIDADE DO AR EM
CIDADES BRASILEIRAS**

Andreas Vinícius Araújo de Andrade
Arthur do Amaral Barreto
Cauã de Andrade Nogueira
Gabriel Fonseca de Lemos

SOROCABA – SP
2026

Andreas Vinícius Araújo de Andrade
Arthur do Amaral Barreto
Cauã de Andrade Nogueira
Gabriel Fonseca de Lemos

**DO DADO BRUTO À DECISÃO: CONSTRUÇÃO DE UM DATA WAREHOUSE
PARA MONITORAMENTO DA QUALIDADE DO AR EM CIDADES
BRASILEIRAS**

Relatório técnico apresentado à disciplina de Business
Intelligence e Big Data, do curso de Análise e
Desenvolvimento de Sistemas da Fatec Sorocaba, como
requisito parcial de avaliação da atividade prática de Data
Warehouse e ETL.

Orientador: Prof. Dr. Bruno Aguilar da Cunha

SOROCABA – SP
2026

SUMÁRIO

1 INTRODUÇÃO.....	4
2 OBJETIVOS.....	4
3 METODOLOGIA.....	4
3.1 Fonte de dados e arquitetura.....	4
3.2 Declaração do grão.....	5
3.3 Extração (Extract).....	5
3.4 Transformação e qualidade de dados (Transform).....	5
3.5 Modelagem dimensional e carga (Load).....	6
4 DICIONÁRIO DE DADOS DO DATA WAREHOUSE.....	6
5 CONSULTAS ANALÍTICAS E RESULTADOS.....	7
5.1 Comparativo de AQI máximo e médias de PM2.5 por cidade.....	8
5.2 Comparação entre dias úteis e finais de semana.....	8
5.3 Dias com qualidade do ar moderada ou ruim (AQI > 50).....	8
6 CONCLUSÕES GERENCIAIS.....	9
6.1 Qualidade do ar por cidade (AQI e PM2.5).....	9
6.2 Comparativo entre dias úteis e finais de semana.....	9
6.3 Decisão gerencial para a empresa.....	9
7 CONSIDERAÇÕES FINAIS.....	9
REFERÊNCIAS.....	10

1 INTRODUÇÃO

Este relatório documenta o desenvolvimento de um pequeno ambiente analítico de Business Intelligence, construído a partir de dados públicos de qualidade do ar, no âmbito da atividade prática da disciplina de Business Intelligence e Big Data, ministrada pelo Prof. Dr. Bruno Aguilar da Cunha, no curso de Análise e Desenvolvimento de Sistemas da Fatec Sorocaba.

O trabalho parte de uma situação-problema hipotética: uma empresa pretende realizar eventos em diferentes cidades brasileiras e deseja, antes de definir datas e locais, comparar as condições ambientais históricas de cada cidade. Para apoiar essa decisão, foi construído um Data Warehouse (DW) dimensional alimentado por dados reais obtidos na Air Quality API da Open-Meteo, percorrendo as etapas de extração, transformação, carga e análise (processo ETL).

2 OBJETIVOS

O objetivo geral deste trabalho é construir um ambiente analítico simplificado capaz de responder a perguntas de negócio sobre a qualidade do ar em cidades brasileiras, a partir de dados extraídos de uma API pública. De forma específica, o grupo buscou:

- interpretar a resposta JSON retornada pela API de qualidade do ar;
- distinguir dados brutos (staging), dados tratados e informações analíticas;
- aplicar regras de limpeza, padronização e validação sobre os dados horários;
- definir o grão da tabela fato e construir as dimensões correspondentes;
- carregar o modelo dimensional resultante em um banco de dados SQLite;
- responder perguntas de negócio por meio de consultas SQL.

3 METODOLOGIA

3.1 Fonte de dados e arquitetura

Foi utilizada a Air Quality API da Open-Meteo (<https://air-quality-api.open-meteo.com/v1/air-quality>), que disponibiliza, sem necessidade de chave de acesso, séries horárias de poluentes atmosféricos e do índice de qualidade do ar (AQI). O grupo selecionou quatro cidades brasileiras de diferentes perfis e regiões — Sorocaba (SP), Olinda (PE), Ourinhos (SP) e São Paulo (SP) — e extraiu dados horários referentes a todo o mês de julho de 2025 (01/07/2025 a 31/07/2025), totalizando 2.976 registros horários brutos preservados na área de staging.

3.2 Declaração do grão

Antes da modelagem, o grupo definiu explicitamente o nível de detalhe armazenado na tabela fato, conforme boas práticas de modelagem dimensional:

“A tabela fato_qualidade_ar_diario possui o grão de uma linha para cada cidade em cada dia.”

Ou seja, os dados horários coletados na API foram agregados para a granularidade diária, de modo que cada combinação de cidade e data corresponda a exatamente um registro na tabela fato.

3.3 Extração (Extract)

A extração foi realizada por meio de requisições HTTP (biblioteca requests) para cada uma das quatro cidades, solicitando as variáveis horárias PM10, PM2.5, dióxido de nitrogênio (NO2), ozônio (O3) e o índice de qualidade do ar norte-americano (US AQI). O método `raise_for_status()` foi utilizado para interromper o processo em caso de erro HTTP, e os DataFrames resultantes de cada cidade foram concatenados em um único DataFrame bruto (`df_bruto`). Antes de qualquer transformação, esse conteúdo foi preservado em disco no arquivo `staging_qualidade_ar.csv`, constituindo a área de staging exigida pela atividade — uma camada intermediária que garante auditoria e possibilidade de reproprocessamento.

3.4 Transformação e qualidade de dados (Transform)

Na etapa de transformação, a coluna de tempo (time) foi convertida para o tipo `datetime` e as colunas de medição (PM10, PM2.5, NO2, ozônio e AQI) foram convertidas para tipo numérico com `pd.to_numeric(errors="coerce")`, tratando eventuais valores inconsistentes como nulos. A verificação sobre o arquivo de staging não identificou valores ausentes nas 2.976 linhas extraídas.

Em seguida, os dados horários foram agregados para o grão diário por meio de `groupby(["cidade", "estado", "regiao", "latitude", "longitude", "data"])`, gerando as métricas de média e máximo por dia. Após a agregação, foi aplicada a deduplicação `drop_duplicates(subset=["cidade", "data"], keep="last")`, garantindo que cada cidade possua no máximo um registro por dia — regra de negócio essencial para manter a consistência do grão definido. As métricas agregadas foram arredondadas para duas casas decimais, padronizando a granularidade analítica.

3.5 Modelagem dimensional e carga (Load)

O modelo dimensional adotado segue o esquema estrela, composto por duas dimensões (dim_tempo e dim_local) e uma tabela fato (fato_qualidade_ar_diario), conectadas por chaves substitutas (surrogate keys) tempo_sk e local_sk. A dimensão de tempo foi derivada das datas presentes na fato, com atributos de calendário (ano, mês, dia, trimestre, dia da semana em português e indicador de fim de semana). A dimensão de local foi construída a partir do cadastro das quatro cidades selecionadas, incluindo estado, região e coordenadas geográficas. As três tabelas foram carregadas em um banco de dados SQLite (dw_qualidade_ar.db), com chaves estrangeiras habilitadas (PRAGMA foreign_keys = ON) e chaves primárias compostas (tempo_sk, local_sk) na tabela fato. A verificação de integridade referencial (PRAGMA foreign_key_check) não identificou nenhuma inconsistência, confirmando que todas as 124 linhas da fato (4 cidades × 31 dias) referenciam corretamente as dimensões.

4 DICIONÁRIO DE DADOS DO DATA WAREHOUSE

As tabelas a seguir descrevem a estrutura, os tipos de dados e as regras de negócio aplicadas em cada tabela do Data Warehouse construído.

Tabela 1 — Estrutura da tabela dim_tempo

Coluna	Tipo	Descrição
tempo_sk	INTEGER (PK)	Chave substituta temporal, no formato AAAAMMDD.
data	TEXT	Data de referência, no formato AAAA-MM-DD.
ano, mes, dia	INTEGER	Atributos de calendário extraídos da data.
trimestre	INTEGER	Trimestre do ano (1 a 4).
dia_semana	TEXT	Nome do dia da semana, em português.
fim_de_semana	INTEGER	Indicador binário: 1 para sábado/domingo; 0 para dia útil.

Fonte: Elaborado pelo grupo (2026), com base nos dados extraídos da API Open-Meteo Air Quality.

Tabela 2 — Estrutura da tabela dim_local

Coluna	Tipo	Descrição
local_sk	INTEGER (PK)	Chave substituta sequencial da localização.
cidade, estado	TEXT	Informações geográficas administrativas da cidade.
regiao	TEXT	Região geográfica brasileira (Sudeste, Nordeste).
latitude, longitude	REAL	Coordenadas geográficas utilizadas na consulta à API.

Fonte: Elaborado pelo grupo (2026), com base nos dados extraídos da API Open-Meteo Air Quality.

Tabela 3 — Estrutura da tabela fato_qualidade_ar_diario

Coluna	Tipo	Descrição
tempo_sk / local_sk	INTEGER (FK)	Chaves estrangeiras que formam a chave primária composta da tabela fato.
media_pm2_5, maximo_pm2_5	REAL	Média e valor máximo diário de PM2.5 ($\mu\text{g}/\text{m}^3$).
media_pm10	REAL	Média diária de PM10 ($\mu\text{g}/\text{m}^3$).
media_ozonio	REAL	Média diária de ozônio ($\mu\text{g}/\text{m}^3$).
media_no2	REAL	Média diária de dióxido de nitrogênio ($\mu\text{g}/\text{m}^3$).
maior_aqi	REAL	Maior valor do índice de qualidade do ar (US AQI) registrado no dia.
horas_aqi_ruim	INTEGER	Quantidade de horas no dia em que o US AQI superou 50.
dia_qualidade_ruim	INTEGER	Indicador binário: 1 se maior_aqi > 50, senão 0.

Fonte: Elaborado pelo grupo (2026), com base nos dados extraídos da API Open-Meteo Air Quality.

5 CONSULTAS ANALÍTICAS E RESULTADOS

Foram elaboradas três consultas SQL sobre o Data Warehouse, unindo a tabela fato às dimensões de tempo e local, com o objetivo de responder às perguntas de negócio propostas pela atividade.

5.1 Comparativo de AQI máximo e médias de PM2.5 por cidade

Tabela 4 — AQI máximo e PM2.5 por cidade (julho de 2025)

Cidade	UF	PM2.5 médio (µg/m³)	Pico PM2.5 (µg/m³)	Pior AQI registrado
São Paulo	SP	26,62	77,3	184,0
Ourinhos	SP	11,04	43,1	78,0
Sorocaba	SP	10,61	43,1	113,0
Olinda	PE	6,22	9,8	44,0

Fonte: Elaborado pelo grupo (2026), com base nos dados extraídos da API Open-Meteo Air Quality.

5.2 Comparação entre dias úteis e finais de semana

Tabela 5 — PM2.5 e PM10 médios por cidade, dia útil versus final de semana

Cidade	Tipo de dia	PM2.5 médio (µg/m³)	PM10 médio (µg/m³)
Olinda	Dia útil	6,36	10,05
Olinda	Final de semana	5,85	9,47
Ourinhos	Dia útil	10,03	10,45
Ourinhos	Final de semana	13,92	13,88
Sorocaba	Dia útil	9,62	10,05
Sorocaba	Final de semana	13,44	13,96
São Paulo	Dia útil	24,08	24,83
São Paulo	Final de semana	33,91	34,44

Fonte: Elaborado pelo grupo (2026), com base nos dados extraídos da API Open-Meteo Air Quality.

5.3 Dias com qualidade do ar moderada ou ruim (AQI > 50)

Tabela 6 — Quantidade de dias com AQI acima de 50, por cidade

Cidade	Dias com AQI > 50
São Paulo	28
Ourinhos	27
Sorocaba	24
Olinda	0

Fonte: Elaborado pelo grupo (2026), com base nos dados extraídos da API Open-Meteo Air Quality.

6 CONCLUSÕES GERENCIAIS

6.1 Qualidade do ar por cidade (AQI e PM2.5)

São Paulo registrou a pior qualidade do ar entre as cidades analisadas no período de julho de 2025, atingindo um pico de AQI de 184,0 — classificado como categoria "insalubre" — e a maior média diária de PM2.5, de 26,62 $\mu\text{g}/\text{m}^3$. Olinda, por outro lado, apresentou a melhor qualidade do ar entre as quatro localidades, com AQI máximo de 44,0 (categoria "boa") e média de PM2.5 de apenas 6,22 $\mu\text{g}/\text{m}^3$. Sorocaba e Ourinhos mantiveram níveis médios moderados (~10 a 11 $\mu\text{g}/\text{m}^3$).

6.2 Comparativo entre dias úteis e finais de semana

Nas cidades do interior e capital paulista (São Paulo, Sorocaba e Ourinhos), os níveis médios de poluição tendem a aumentar significativamente nos finais de semana durante o mês de julho. Em São Paulo, por exemplo, a média de PM2.5 subiu de 24,08 $\mu\text{g}/\text{m}^3$ nos dias úteis para 33,91 $\mu\text{g}/\text{m}^3$ nos finais de semana. Em Sorocaba e Ourinhos, a poluição aumentou cerca de 35% a 40% aos sábados e domingos — um padrão associado ao tráfego rodoviário intensificado de lazer e às condições de inversão térmica no inverno da Região Sudeste. Em contrapartida, Olinda manteve níveis baixos e constantes em ambos os períodos.

6.3 Decisão gerencial para a empresa

Com base nos indicadores analisados, recomenda-se que a diretoria priorize a realização de eventos ao ar livre na cidade de Olinda (PE). Caso a escolha seja por Sorocaba ou Ourinhos, os eventos ao ar livre devem ser agendados preferencialmente em dias úteis ou no período da manhã. Deve-se evitar a definição de datas de grandes eventos abertos em São Paulo durante o mês de julho, salvo com plano de contingência para locais fechados ou climatizados, em função dos elevados índices de poluição que ultrapassam os limites recomendados pela Organização Mundial da Saúde (OMS).

7 CONSIDERAÇÕES FINAIS

A atividade permitiu à equipe percorrer, de forma prática, todo o ciclo de um projeto de Business Intelligence: da extração de dados brutos em uma API pública até a geração de conclusões gerenciais sustentadas por consultas SQL sobre um modelo dimensional. A definição

explícita do grão da tabela fato, a preservação da área de staging e a validação da integridade referencial do banco de dados mostraram-se etapas essenciais para garantir a confiabilidade das análises finais. Os dados evidenciam de forma clara que a extração de informação útil para a tomada de decisão depende diretamente da qualidade dos tratamentos aplicados aos dados brutos e da coerência entre o grão definido e as perguntas de negócio que se pretende responder.

REFERÊNCIAS

OPEN-METEO. Air Quality API. Disponível em: <https://air-quality-api.open-meteo.com/en/docs/air-quality-api>. Acesso em: 20 ago. 2026.

OPEN-METEO. Historical Weather API. Disponível em: <https://air-quality-api.open-meteo.com/en/docs/historical-weather-api>. Acesso em: 20 ago. 2026.

CUNHA, Bruno Aguilar da. Do dado bruto à decisão: Data Warehouse + ETL + API + Python. Sorocaba: Fatec Sorocaba, 2026. Material didático da disciplina Business Intelligence e Big Data.

KIMBALL, Ralph; ROSS, Margy. The Data Warehouse Toolkit: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 14724: informação e documentação — trabalhos acadêmicos — apresentação. Rio de Janeiro: ABNT, 2011.